

מודלים סטטיסטיים ויישומיהם 52518 תשע"ח – פתרון תרגיל 8

להגשה עד 25.12.17 בשעה 23:55

1. קובץ הנתונים ex8dat.txt מציג ניסוי לבדיקת יעילותה של תרופה לשיפור תפקוד הכליות בקרב חולי סכרת. עמודות הקובץ הן (משמאל לימין במסד הנתונים) ID, Dose Group, Type of Diabetes (מדד תפקוד הכליה).

א. הריצו ANOVA דו-כווני ללא אינטראקציות עם המשקלות

$$\pi_i = \frac{n_{i.}}{N}, \tau_j = \frac{n_{.j}}{N}$$

ב. מצאו ביטוי עבור α_I לפי $\alpha_1, \dots, \alpha_{I-1}, n_1, \dots, n_I$.

ג. במודל נטול האינטראקציות, מצאו את המטריצה C המקיימת $\Delta = C \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_{I-1} \end{pmatrix}$, כאשר Δ הוא אוסף כל

הקונטרסטים הזוגיים (מהצורה $\alpha_i - \alpha_{i'}$).

ד. במודל נטול האינטראקציות, חשבו בעזרת השיטה המדויקת רווחי סמך בו-זמניים לכל הקונטרסטים הזוגיים (מהצורה $\alpha_i - \alpha_{i'}$).

ה. חזרו על הסעיפים הקודמים, הפעם במודל עם אינטראקציות ותוך שימוש במשקלות הבאים:

$$\pi_i = \frac{1}{I}, \tau_1 = 0.75, \tau_2 = 0.25$$

א. הניתוח המתקבל:

	DF	Sum Sq	MSE	F	P(> F)
A	3	47.4813	15.8271	22.1303	$2.0042 \cdot 10^{-12}$
B	1	0.4460	0.446	0.6236	0.4306
E	201	143.7509	0.7152		

ב.

$$I = 4 \rightarrow \alpha_4 = -\frac{n_{1.}}{n_{4.}}\alpha_1 - \frac{n_{2.}}{n_{4.}}\alpha_2 - \frac{n_{3.}}{n_{4.}}\alpha_3$$

ג.

$$\Delta = \begin{pmatrix} \alpha_1 - \alpha_2 \\ \alpha_1 - \alpha_3 \\ \alpha_2 - \alpha_3 \\ \alpha_1 - \alpha_4 \\ \alpha_2 - \alpha_4 \\ \alpha_3 - \alpha_4 \end{pmatrix} = \begin{pmatrix} \alpha_1 - \alpha_2 \\ \alpha_1 - \alpha_3 \\ \alpha_2 - \alpha_3 \\ \alpha_1 - \left(-\frac{n_{1.}}{n_{4.}}\alpha_1 - \frac{n_{2.}}{n_{4.}}\alpha_2 - \frac{n_{3.}}{n_{4.}}\alpha_3\right) \\ \alpha_2 - \left(-\frac{n_{1.}}{n_{4.}}\alpha_1 - \frac{n_{2.}}{n_{4.}}\alpha_2 - \frac{n_{3.}}{n_{4.}}\alpha_3\right) \\ \alpha_3 - \left(-\frac{n_{1.}}{n_{4.}}\alpha_1 - \frac{n_{2.}}{n_{4.}}\alpha_2 - \frac{n_{3.}}{n_{4.}}\alpha_3\right) \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & -1 & 0 \\ 1 & 0 & -1 \\ 0 & 1 & -1 \\ 1 + \frac{n_{1.}}{n_{4.}} & \frac{n_{2.}}{n_{4.}} & \frac{n_{3.}}{n_{4.}} \\ \frac{n_{1.}}{n_{4.}} & 1 + \frac{n_{2.}}{n_{4.}} & \frac{n_{3.}}{n_{4.}} \\ \frac{n_{1.}}{n_{4.}} & \frac{n_{2.}}{n_{4.}} & 1 + \frac{n_{3.}}{n_{4.}} \end{pmatrix}}_C \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{pmatrix}$$

ד. יש לנו את המטריצה $D = (Q_1^T Q_1)^{-1}$ המכילה את המידע הרלוונטי על α_i , מטריצת הקונטרסטים היא C

לעיל. נגדיר Ω באברי האלבסון של CDC בחזקת $\frac{1}{2}$ – ואז את $R = \Omega CDC^T \Omega$, עבור $\alpha = 0.05$ נקבל את רווחי

הסמך הבאים:

$$CI = \begin{bmatrix} 0.0350 & 0.8984 \\ 0.3444 & 1.2115 \\ -0.1243 & 0.7468 \\ 0.8819 & 1.7365 \\ 0.4132 & 1.2717 \\ 0.0999 & 0.9626 \end{bmatrix}$$

ה. הניתוח המתקבל:

	DF	Sum Sq	MSE	F	$P(> F)$
A	3	37.1992	12.3997	17.3348	$4.9209 \cdot 10^{-10}$
B	1	0.4292	0.4292	0.6000	0.4395
AB	3	2.1196	0.7065	0.9877	0.3996
E	198	141.6313	0.7153		

ורוחי הסמך:

$$CI = \begin{bmatrix} -0.1032 & 0.8278 \\ 0.2667 & 1.2100 \\ -0.0873 & 0.8395 \\ 0.7568 & 1.6774 \\ 0.4076 & 1.3021 \\ 0.0298 & 0.9277 \end{bmatrix}$$

קוד R לשאלה זו:

```
# READ DATA
indat = read.table('ex8dat.txt')
A = indat[,2]
B = indat[,3]
Y = indat[,4]
nA = table(A)
nB = table(B)
#In the code that follows, I use the fact that I know that the possible values of A are 1,2,3,4
#and the possible values of B are 1,2. This could be avoided with a bit of extra coding.
```

```
#Q1 Parts A and B - Set up variables to be used in regressions
```

```
N = length(Y)
XA1 = rep(0,N)
XA2 = rep(0,N)
XA3 = rep(0,N)
XB = rep(0,N)
nA14 = nA[1]/nA[4]
nA24 = nA[2]/nA[4]
nA34 = nA[3]/nA[4]
nB12 = nB[1]/nB[2]
for (r in 1:N) {
  if (A[r]==1) {XA1[r]=1}
  if (A[r]==2) {XA2[r]=1}
  if (A[r]==3) {XA3[r]=1}
  if (A[r]==4) {
    XA1[r] = -nA14
    XA2[r] = -nA24
    XA3[r] = -nA34
  }
  if (B[r]==1) {XB[r]=1}
  if (B[r]==2) {XB[r]=-nB12}
}
```

```
#Q1 Parts A and B - Run regressions
```

```
model.a.b = lm(Y ~ XA1 + XA2 + XA3 + XB)
model.a = lm(Y ~ XA1 + XA2 + XA3)
model.b = lm(Y ~ XB)
sse.a.b = sum(model.a.b$residuals^2)
sse.a = sum(model.a$residuals^2)
sse.b = sum(model.b$residuals^2)
```

```
#Q1 Parts A and B - Compute SS, MS, F, and p values
```

```
sse.no.int = sse.a.b
mse.no.int = sse.no.int/(N-5)
```

```

ssa.no.int = sse.b - sse.a.b
msa.no.int = ssa.no.int/3
F.A = msa.no.int/mse.no.int
p.A = 1 - pf(F.A,3,N-5)
ssb.no.int = sse.a - sse.a.b
msb.no.int = ssb.no.int
F.B = msb.no.int/mse.no.int
p.B = 1 - pf(F.B,1,N-5)
df = c(3,1,N-5)
SS = c(ssa.no.int,ssb.no.int,sse.no.int)
MS = c(msa.no.int,msb.no.int,mse.no.int)
F = c(F.A,F.B,NA)
p.value = c(p.A,p.B,NA)
anova.no.int = cbind(df,SS,MS,F,p.value)
anova.no.int = data.frame(anova.no.int)
rownames(anova.no.int) = c('A','B','Error')
anova.no.int

```

#Q1 Part C

```

C = rbind(
  c(1,-1,0),
  c(1,0,-1),
  c(0,1,-1),
  c(1+nA14,nA24,nA34),
  c(nA14,1+nA24,nA34),
  c(nA14,nA24,1+nA34))
eta = coef(model.a.b)
alf = eta[2:4]
del.rs.hat = C %*% alf
xmat = cbind(rep(1,N),XA1,XA2,XA3,XB)
G = mse.no.int * solve(t(xmat)%*%xmat)
Ga = G[2:4,2:4]
cov.dif = C %*% Ga %*% t(C)
sd.dif = sqrt(diag(cov.dif))
sd.dif.mat.i = diag(1/sd.dif)
R = sd.dif.mat.i %*% cov.dif %*% sd.dif.mat.i
library(mvtnorm)
ts = qmvt(0.95,tail='both.tails',corr=R, df = 217)
tstar = ts$quantile
cihw = tstar * sd.dif
lower.conf.lim = del.rs.hat - cihw
upper.conf.lim = del.rs.hat + cihw
r.index = c(1,1,2,1,2,3)
s.index = c(2,3,3,4,4,4)
result.C = cbind(r.index,s.index,del.rs.hat,lower.conf.lim,upper.conf.lim)
result.C = data.frame(result.C)
names(result.C) = c('r','s','del.rs.hat','lower.conf.lim','upper.conf.lim')
result.C

```

#Q1 Part D

we have to express alpha4 in terms of the other alphas

```

alf4coef = -c(nA14,nA24,nA34)
c = c(-1,0,0.5) + 0.5*alf4coef
psi.hat = sum(c*alf)
sd = sqrt(t(c) %*% Ga %*% c)
fcrit = qf(0.95,3,N-5)
xi = sqrt(3*fcrit)
cihw = xi * sd
psi.L = psi.hat - cihw
psi.U = psi.hat + cihw
result.D = cbind(psi.hat,psi.L,psi.U)

```

```

result.D = data.frame(result.D)
names(result.D) = c('psi.hat','psi.L','psi.U')
result.D

```

#ADDED 5778: REDO VARIABLES WITH NEW WEIGHTS

```

N = length(Y)
XA1 = rep(0,N)
XA2 = rep(0,N)
XA3 = rep(0,N)
XB = rep(0,N)
for (r in 1:N) {
  if (A[r]==1) {XA1[r]=1}
  if (A[r]==2) {XA2[r]=1}
  if (A[r]==3) {XA3[r]=1}
  if (A[r]==4) {
    XA1[r] = -1
    XA2[r] = -1
    XA3[r] = -1
  }
  if (B[r]==1) {XB[r]=1}
  if (B[r]==2) {XB[r]=-3}
}

```

#Q1 Part E - Set up variables and run regressions

```

XAB1 = XA1*XB
XAB2 = XA2*XB
XAB3 = XA3*XB
full = lm(Y ~ XA1 + XA2 + XA3 + XB + XAB1 +XAB2 + XAB3)
model.a.ab = lm(Y ~ XA1 + XA2 + XA3 + XAB1 +XAB2 + XAB3)
model.b.ab = lm(Y ~ XB + XAB1 + XAB2 + XAB3)
sse.full = sum(full$residuals^2)
sse.a.ab = sum(model.a.ab$residuals^2)
sse.b.ab = sum(model.b.ab$residuals^2)

```

#Q1 Part E - Compute SS, MS, F, and p values

```

sse = sse.full
mse = sse/(N-8)
ssa = sse.b.ab - sse
msa = ssa/3
F.A = msa/mse
p.A = 1 - pf(F.A,3,N-8)
ssb = sse.a.ab - sse
msb = ssb
F.B = msb/mse
p.B = 1 - pf(F.B,1,N-8)
ssab = sse.a.b - sse
msab = ssab/3
F.AB = msab/mse
p.AB = 1 - pf(F.AB,3,N-8)
df = c(3,1,3,N-8)
SS = c(ssa,ssb,ssab,sse)
MS = c(msa,msb,msab,mse)
F = c(F.A,F.B,F.AB,NA)
p.value = c(p.A,p.B,p.AB,NA)
anova = cbind(df,SS,MS,F,p.value)
anova = data.frame(anova)
rownames(anova) = c('A','B','AB','Error')
anova

```

#Q1 Part E - Pairwise comparisons

#Same C matrix as before

```

eta = coef(full)
alf = eta[2:4]
del.rs.hat = C %*% alf
xmat = cbind(rep(1,N),XA1,XA2,XA3,XB,XAB1,XAB2,XAB3)
G = mse * solve(t(xmat)%*%xmat)
Ga = G[2:4,2:4]
cov.dif = C %*% Ga %*% t(C)
sd.dif = sqrt(diag(cov.dif))
sd.dif.mat.i = diag(1/sd.dif)
R = sd.dif.mat.i %*% cov.dif %*% sd.dif.mat.i
ts = qmvt(0.95,tail='both.tails',corr=R, df = 198)
tstar = ts$quantile
cihw = tstar * sd.dif
lower.conf.lim = del.rs.hat - cihw
upper.conf.lim = del.rs.hat + cihw
r.index = c(1,1,2,1,2,3)
s.index = c(2,3,3,4,4,4)
result.E2 = cbind(r.index,s.index,del.rs.hat,lower.conf.lim,upper.conf.lim)
result.E2 = data.frame(result.E2)
names(result.E2) = c('r','s','del.rs.hat','lower.conf.lim','upper.conf.lim')
result.E2

```

2. יהיה מודל ANOVA דו-כווני (עם או בלי אינטראקציה). כמו בכתה, נסמן ב- H את הבלוק במטריצה $(X^T X)^{-1}$. המתייחס לאיברים $\alpha_1, \dots, \alpha_{I-1}$. נסמן ב- \hat{Y} את וקטור התחזיות תחת המודל המלא וב- $\hat{Y}^{(0)}$ את וקטור התצפיות תחת ההשערה $H_A: \alpha_1 = \dots = \alpha_I = 0$. ניתן להראות כי $\|\hat{Y} - \hat{Y}^{(0)}\|^2 = \hat{\alpha}^T H^{-1} \hat{\alpha}$ ואז F_A (סטטיסטי המבחן F המשמש לבדיקת ההשערה H_A) מקיים

$$F_A = \frac{\hat{\alpha}^T H^{-1} \hat{\alpha} / (I - 1)}{s^2}$$

תחת H_A , כאשר $F_A \sim F_{I-1,p}$ הוא מספר דרגות החופש $(N - IJ)$ במודל עם אינטראקציות, $N - I - J + 1$ במודל נטול אינטראקציות).

א. עבור נתוני הקובץ `ex8dat.txt`, ודאו כי מתקיימת הזהות $F_A = \frac{\hat{\alpha}^T H^{-1} \hat{\alpha} / (I-1)}{s^2}$.

ב. נסמן את הערך האמתי של הוקטור α באופן α^* . הוכיחו כי לכל α^* מתקיים $\frac{(\hat{\alpha} - \alpha^*)^T H^{-1} (\hat{\alpha} - \alpha^*) / (I - 1)}{s^2} \sim F_{I-1,p}$

ג. השתמשו בתוצאות הנ"ל כדי לוודא את נכונות רווח הסמך שהוצג בכתה עבור רווח סמך בשיטת $Scheffé$. בססו את ההוכחה שלכם על ההוכחה לרווח סמך בשיטת $Scheffé$ במקרה החד-כווני.

א. קוד R (המשך לשאלה 1):

```

#Q2 - Set up variables
XA1 = rep(0,N)
XA2 = rep(0,N)
XA3 = rep(0,N)
XB = rep(0,N)
for (r in 1:N) {
  if (A[r]==1) {XA1[r]=1}
  if (A[r]==2) {XA2[r]=1}
  if (A[r]==3) {XA3[r]=1}
  if (A[r]==4) {
    XA1[r] = -1
    XA2[r] = -1
    XA3[r] = -1
  }
  if (B[r]==1) {XB[r]=1}
  if (B[r]==2) {XB[r]=-0.15/0.85}
}

```

```

}
XAB1 = XA1*XB
XAB2 = XA2*XB
XAB3 = XA3*XB

#Q2 - Run regressions
full = lm(Y ~ XA1 + XA2 + XA3 + XB + XAB1 + XAB2 + XAB3)
model.b.ab = lm(Y ~ XB + XAB1 + XAB2 + XAB3)
sse.full = sum(full$residuals^2)
sse.b.ab = sum(model.b.ab$residuals^2)
sse = sse.full

#Q2 - Compute F.A value using first method
ssa = sse.b.ab - sse
msa = ssa/3
mse = sse/(N-8)
F.first = msa/mse
F.first

#Q2 - Compute F.A value using second method
eta = coef(full)
alf = eta[2:4]
xmat = cbind(rep(1,N),XA1,XA2,XA3,XB,XAB1,XAB2,XAB3)
G = mse * solve(t(xmat)%*%xmat)
Ga = G[2:4,2:4]
F.second = t(alf) %*% solve(Ga) %*% alf / 3
F.second

```

ב. במודל עם אינטראקציות מתקיים:

$$Y = X\eta + \epsilon \rightarrow \hat{\eta} = \begin{pmatrix} \hat{\mu} \\ \hat{\alpha} \\ \hat{\beta} \\ \hat{\gamma} \end{pmatrix} = (X^T X)^{-1} X^T Y$$

אז עבור G שהיא השורות $2, \dots, I$ של המטריצה $(X^T X)^{-1}$ יתקיים $\hat{\alpha} = G X^T Y$. בעת, נסמן את הערך האמתי של η באופן η^* , מתקיים $\eta^* = (X^T X)^{-1} X^T X \eta^* = G X^T X \eta^*$ ולכן $\alpha^* = G X^T X \eta^*$, נסמן:

$$\Delta = \hat{\alpha} - \alpha^* = G X^T Y - G X^T X \eta^* = G X^T (Y - X \eta^*) = G X^T \tilde{Y}$$

כלומר Δ זהה לאומד של α אותו היינו מקבלים עבור הנתונים \tilde{Y} , אבל עבור הוקטור α^* מתאפס ולכן נקבל כי

$$\frac{(\hat{\alpha} - \alpha^*)^T H^{-1} (\hat{\alpha} - \alpha^*) / (I - 1)}{\tilde{s}^2} \sim F_{I-1, N-I}$$

כאשר \tilde{s}^2 הוא הערך של s^2 עבור נתוני \tilde{Y} , כלומר כדי לסיים עלינו להוכיח כי $\tilde{s}^2 = s^2$:

$$P_X = X(X^T X)^{-1} X^T \rightarrow \tilde{e} = (I - P_X) \tilde{Y} = (I - P_X)(Y - X \eta^*) = Y - P_X Y - X \eta^* + P_X X \eta^*$$

$$= (Y - \hat{Y}) + (X \eta^* - X(X^T X)^{-1} X^T X \eta^*) = e + (X \eta^* - X \eta^*) = e \rightarrow \tilde{s}^2 = s^2$$

ההוכחה למודל ללא אינטראקציות זהה.

ג. המטריצה H היא חיובית וסימטרית, לכן קיימת מטריצה A עבורה $A A^T = H$, $(A^{-1})^T A^{-1} = H^{-1}$. אחת

הדרכים למצוא את A היא דרך פירוק ספקטרלי: אם $H = U \Lambda U^T$ אז נוכל לקבל $A = U \Lambda^{\frac{1}{2}} U^T$. בעת:

$$|\hat{\psi}(d) - \psi(d)| = |d^T \hat{\alpha} - d^T \alpha^*| = |d^T (\hat{\alpha} - \alpha^*)| = |d^T A A^{-1} (\hat{\alpha} - \alpha^*)| = |(A^T d)^T (A^{-1} (\hat{\alpha} - \alpha^*))|$$

מא"ש קושי-שוורץ נקבל:

$$|(A^T d)^T (A^{-1} (\hat{\alpha} - \alpha^*))| \leq \|A^T d\| \cdot \|A^{-1} (\hat{\alpha} - \alpha^*)\| = \left((d^T A A^T d) \left((\hat{\alpha} - \alpha^*)^T A^{-1} A^{-1} (\hat{\alpha} - \alpha^*) \right) \right)^{\frac{1}{2}}$$

$$= \left((d^T H d) ((\hat{\alpha} - \alpha^*)^T H^{-1} (\hat{\alpha} - \alpha^*)) \right)^{\frac{1}{2}}$$

כלומר

$$\max_{d \neq 0} \frac{|\hat{\psi}(d) - \psi(d)|}{s\sqrt{V(d)}} = \left(\frac{(\hat{\alpha} - \alpha^*)^T H^{-1}(\hat{\alpha} - \alpha^*)}{\hat{s}^2} \right)^{\frac{1}{2}} = (I-1)^{\frac{1}{2}} \left(\frac{(\hat{\alpha} - \alpha^*)^T H^{-1}(\hat{\alpha} - \alpha^*) / (I-1)}{\hat{s}^2} \right)^{\frac{1}{2}}$$

ולכן

$$\max_{d \neq 0} \frac{|\hat{\psi}(d) - \psi(d)|}{s\sqrt{(I-1)V(d)}} = \left(\frac{(\hat{\alpha} - \alpha^*)^T H^{-1}(\hat{\alpha} - \alpha^*) / (I-1)}{\hat{s}^2} \right)^{\frac{1}{2}}$$

הראינו בסעיף ב' כי $\frac{(\hat{\alpha} - \alpha^*)^T H^{-1}(\hat{\alpha} - \alpha^*) / (I-1)}{\hat{s}^2} \sim F_{I-1,p}$ ולכן:

$$\begin{aligned} P\left(|\hat{\psi}(d) - \psi(d)| \leq s\sqrt{(I-1)F_{I-1,p}^{1-\omega}V(d)}\right) &= P\left(\max_{d \neq 0} \frac{|\hat{\psi}(d) - \psi(d)|}{s\sqrt{(I-1)V(d)}} \leq \sqrt{F_{I-1,p}^{1-\omega}}\right) \\ &= P\left(\left(\frac{(\hat{\alpha} - \alpha^*)^T H^{-1}(\hat{\alpha} - \alpha^*) / (I-1)}{\hat{s}^2}\right)^{\frac{1}{2}} \leq \sqrt{F_{I-1,p}^{1-\omega}}\right) = 1 - \omega \end{aligned}$$

3. יהי מודל רגרסיה לא-ליניארי עבור משתנה תגובה רציף Y , המוגדר באופן:

$$Y_i = h(\beta^T X_i) + \epsilon_i$$

כאשר h גזירה ומונוטונית עולה וכן $\epsilon_i \sim N(0, \sigma^2)$. מצאו את פונקצית לוג-הנראות וכן את הנגזרות החלקיות שלה

מסדר ראשון.

$$Y_i = h(\beta^T X_i) + \epsilon_i \rightarrow Y_i \sim N(h(\beta^T X_i), \sigma^2)$$

$$L(Y; \beta, \sigma^2, X) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(Y_i - h(\beta^T X_i))^2}{2\sigma^2}\right\} = (2\pi\sigma^2)^{-\frac{n}{2}} \cdot \prod_{i=1}^n \exp\left\{-\frac{(Y_i - h(\beta^T X_i))^2}{2\sigma^2}\right\}$$

$$\begin{aligned} l(Y; \beta, \sigma^2, X) &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) + \sum_{i=1}^n -\frac{(Y_i - h(\beta^T X_i))^2}{2\sigma^2} \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - h(\beta^T X_i))^2 \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i^2 - 2Y_i h(\beta^T X_i) + (h(\beta^T X_i))^2) \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \left(\sum_{i=1}^n Y_i^2 - 2 \sum_{i=1}^n Y_i h(\beta^T X_i) + \sum_{i=1}^n (h(\beta^T X_i))^2 \right) \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2} (\sigma^2)^{-1} \left(\sum_{i=1}^n Y_i^2 - 2 \sum_{i=1}^n Y_i h(\beta^T X_i) + \sum_{i=1}^n (h(\beta^T X_i))^2 \right) \\ \frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} - \frac{1}{2} \cdot -1 \cdot (\sigma^2)^{-2} \cdot \left(\sum_{i=1}^n Y_i^2 - 2 \sum_{i=1}^n Y_i h(\beta^T X_i) + \sum_{i=1}^n (h(\beta^T X_i))^2 \right) \\ &= \frac{1}{2\sigma^2} \left(\frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - h(\beta^T X_i))^2 - n \right) \end{aligned}$$

$$\frac{\partial l}{\partial \beta} = -\frac{1}{2\sigma^2} \left(-2 \sum_{i=1}^n Y_i h'(\beta^T X_i) + 2 \sum_{i=1}^n (h(\beta^T X_i)) h'(\beta^T X_i) \right) = \frac{1}{2\sigma^2} \sum_{i=1}^n h'(\beta^T X_i) [(h(\beta^T X_i)) - Y_i]$$

4. יהי Y משתנה מקרי בינארי המקיים $Y_i \in \{0,1\}$. נתייחס למודל הלוגיסטי

$$P(Y = 1|X = x) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

כאשר X משתנה מקרי בינארי המקיים $X_i \in \{0,1\}$. הראו כי במקרה זה קיים פתרון אלגברי סגור למשוואת הנראות

ומצאו אותו.

$$L(\beta_0, \beta_1; x) = \prod_{i=1}^N \left(\frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{y_i} \left(1 - \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{1-y_i} = \prod_{i=1}^N \left(\frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{y_i} \left(\frac{1}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^{1-y_i}$$

$$= \prod_{i=1}^N (e^{\beta_0 + \beta_1 x_i})^{y_i} \left(\frac{1}{1 + e^{\beta_0 + \beta_1 x_i}} \right)^1 = \prod_{i=1}^N \frac{(e^{\beta_0 + \beta_1 x_i})^{y_i}}{1 + e^{\beta_0 + \beta_1 x_i}}$$

$$l = \log L = \sum_{i=1}^N y_i \log(e^{\beta_0 + \beta_1 x_i}) - \sum_{i=1}^N \log(1 + e^{\beta_0 + \beta_1 x_i}) = \sum_{i=1}^N y_i (\beta_0 + \beta_1 x_i) - \sum_{i=1}^N \log(1 + e^{\beta_0 + \beta_1 x_i})$$

$$\frac{\partial l}{\partial \beta_0} = \sum_{i=1}^N y_i - \sum_{i=1}^N \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} = 0 \rightarrow \sum_{i=1}^N y_i = \sum_{i=1}^N \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}}$$

$$= \sum_{i=1}^N x_i \cdot \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} + (N - \sum_{i=1}^N x_i) \frac{e^{\beta_0}}{1 + e^{\beta_0}}$$

$$\frac{\partial l}{\partial \beta_1} = \sum_{i=1}^N y_i x_i - \sum_{i=1}^N \frac{x_i e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} = 0 \rightarrow \sum_{i=1}^N y_i x_i = \sum_{i=1}^N \frac{x_i e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}} = \sum_{i=1}^N x_i \cdot \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}}$$

נציב בנוסחה ונקבל:

$$\sum_{i=1}^N y_i = \sum_{i=1}^N x_i \cdot \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} + \left(N - \sum_{i=1}^N x_i \right) \frac{e^{\beta_0}}{1 + e^{\beta_0}} = \sum_{i=1}^N y_i x_i + \left(N - \sum_{i=1}^N x_i \right) \frac{e^{\beta_0}}{1 + e^{\beta_0}}$$

$$\rightarrow \left(N - \sum_{i=1}^N x_i \right) \frac{e^{\beta_0}}{1 + e^{\beta_0}} = \sum_{i=1}^N (y_i - y_i x_i) = \sum_{i=1}^N y_i (1 - x_i) \rightarrow \frac{e^{\beta_0}}{1 + e^{\beta_0}} = \frac{\sum_{i=1}^N y_i (1 - x_i)}{(N - \sum_{i=1}^N x_i)}$$

$$\rightarrow \text{logit} \left(\frac{e^{\beta_0}}{1 + e^{\beta_0}} \right) = \hat{\beta}_0 = \text{logit} \left(\frac{\sum_{i=1}^N y_i (1 - x_i)}{(N - \sum_{i=1}^N x_i)} \right) = \log \left(\frac{\sum_{i=1}^N y_i (1 - x_i)}{N - \sum_{i=1}^N x_i - \sum_{i=1}^N y_i (1 - x_i)} \right)$$

$$= \log \left(\frac{\sum_{i=1}^N y_i (1 - x_i)}{\sum_{i=1}^N (1 - x_i) - \sum_{i=1}^N y_i (1 - x_i)} \right) \rightarrow \boxed{\hat{\beta}_0 = \log \left(\frac{\sum_{i=1}^N y_i (1 - x_i)}{\sum_{i=1}^N (1 - y_i) (1 - x_i)} \right)}$$

כעת נוכל לקבל גם

$$\sum_{i=1}^N y_i x_i = \sum_{i=1}^N x_i \cdot \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} \rightarrow \frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} = \frac{\sum_{i=1}^N y_i x_i}{\sum_{i=1}^N x_i} \rightarrow \text{logit} \left(\frac{\sum_{i=1}^N y_i x_i}{\sum_{i=1}^N x_i} \right) = \text{logit} \left(\frac{e^{\beta_0 + \beta_1}}{1 + e^{\beta_0 + \beta_1}} \right)$$

$$= \hat{\beta}_0 + \hat{\beta}_1 \rightarrow \hat{\beta}_1 = \text{logit} \left(\frac{\sum_{i=1}^N y_i x_i}{\sum_{i=1}^N x_i} \right) - \text{logit} \left(\frac{\sum_{i=1}^N y_i (1 - x_i)}{(N - \sum_{i=1}^N x_i)} \right)$$

$$\rightarrow \text{sigmoid}(\hat{\beta}_1) = \frac{\sum_{i=1}^N y_i x_i}{\sum_{i=1}^N x_i} - \frac{\sum_{i=1}^N y_i (1 - x_i)}{(N - \sum_{i=1}^N x_i)} = \frac{N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i x_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i (1 - x_i)}{\sum_{i=1}^N x_i (N - \sum_{i=1}^N x_i)}$$

$$= \frac{N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N x_i (\sum_{i=1}^N y_i x_i + \sum_{i=1}^N y_i (1 - x_i))}{\sum_{i=1}^N x_i (N - \sum_{i=1}^N x_i)} = \frac{N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{\sum_{i=1}^N x_i (N - \sum_{i=1}^N x_i)}$$

$$\rightarrow \boxed{\hat{\beta}_1 = \text{logit} \left(\frac{N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N x_i \sum_{i=1}^N y_i}{\sum_{i=1}^N x_i (N - \sum_{i=1}^N x_i)} \right)}$$

אם נציג את הנתונים בטבלה 2×2 עם $i, j \in \{0, 1\}$ אז נקבל:

$$\hat{\beta}_0 = \log \left(\frac{n_{01}}{n_{00}} \right)$$

ובאופן דומה

$$\hat{\beta}_1 = \log \left(\frac{n_{00} n_{11}}{n_{01} n_{10}} \right)$$

וזוהו הביטוי הקלאסי עבור לוג מנת יחס הסיכויים בטבלת 2×2 .