

## מודלים סטטיסטיים ויישומיהם 52518 תשע"ח – פתרון בוחן בית 2

להגשה עד 20.12.17 בשעה 23:55

1. (20 נקודות) סטטיסטי המבחן קולמוגורוב-סמירנוב-לילפורס מוגדר באופן

$$D = \max_{t \in [-\infty, \infty]} \left\{ \left| \hat{F}_n(t) - \Phi\left(\frac{t - \bar{X}}{s}\right) \right| \right\}$$

יהי מדגם  $X = x_1, \dots, x_n \sim F$  כאשר  $F$  הינה פונקציית התפלגות רציפה ועולה ממש. נגדיר את המשפחה של ההתפלגויות הנורמליות באופן הבא:

$$N = \left\{ F: F(t) = \Phi\left(\frac{t - \mu}{\sigma}\right), \mu \in \mathbb{R}, \sigma \in \mathbb{R}^+ \right\}$$

הראו כי עבור בדיקת ההשערות  $H_0: F \in N, H_1: F \notin N$ , ההתפלגות של  $D$  (סטטיסטי קולמוגורוב-סמירנוב-לילפורס) תחת השערת האפס היא Distribution Free, כלומר אינה תלויה בפונקציית ההתפלגות  $F$ .

$$D = \max_{t \in [-\infty, \infty]} \left\{ \left| \hat{F}_n(t) - \Phi\left(\frac{t - \bar{X}}{s}\right) \right| \right\}$$

$$\hat{F}_n(t) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}}$$

$$D = \max_{t \in [-\infty, \infty]} \left\{ \left| \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}} - \Phi\left(\frac{t - \bar{X}}{s}\right) \right| \right\}$$

נגדיר  $u = \frac{t - \bar{X}_n}{s}$ , אז  $t = \bar{X}_n + us$ . כיוון שזוהי טרנספורמציה לינארית על  $t$ , המקסימום על  $t$  הוא כמו המקסימום על  $u$  ונוכל לרשום:

$$\begin{aligned} D &= \max_{t \in [-\infty, \infty]} \left\{ \left| \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq t\}} - \Phi\left(\frac{t - \bar{X}}{s}\right) \right| \right\} = \max_{u \in [-\infty, \infty]} \left\{ \left| \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq \bar{X}_n + us\}} - \Phi(u) \right| \right\} \\ &= \max_{u \in [-\infty, \infty]} \left\{ \left| \frac{1}{n} \sum_{i=1}^n I_{\left\{ \frac{X_i - \bar{X}_n}{s} \leq u \right\}} - \Phi(u) \right| \right\} \end{aligned}$$

נגדיר  $Z_i = \frac{X_i - \mu}{\sigma} \rightarrow Z_i \sim N(0,1)$  ונקבל  $X_i = \mu + \sigma Z_i$ , מכאן כי  $\bar{X}_n = \mu + \sigma \bar{Z}_n$  ולכן  $X_i - \bar{X}_n = \sigma(Z_i - \bar{Z}_n)$ . נסמן  $s = \sigma s_Z$  אז  $s_Z^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z}_n)^2$  ונקבל

$$\frac{X_i - \bar{X}_n}{s} = \frac{\sigma(Z_i - \bar{Z}_n)}{\sigma s_Z} = \frac{(Z_i - \bar{Z}_n)}{s_Z}$$

ובסך הכל

$$D = \max_{u \in [-\infty, \infty]} \left\{ \left| \frac{1}{n} \sum_{i=1}^n I_{\left\{ \frac{(Z_i - \bar{Z}_n)}{s_Z} \leq u \right\}} - \Phi(u) \right| \right\}$$

2. (30 נקודות) מצורף קובץ נתונים qn2.txt ממחקר על התפתחות תינוקות. הקבוצות מוגדרות באופן הבא:

(1) נולד פג עם משקל לידה נמוך

(2) נולד פג עם משקל לידה בינוני

(3) נולד באופן תקין

מדד התוצאה הוא מדד התפתחות של התינוקות, רוצים לבחון את ההשערה  $H_0: \mu_1 = \mu_2 = \mu_3$ .

ערכו את המבחנים המתאימים לבדיקת הנחות המודל והסיקו אילו מהן נשמרות ואילו נדחות. במידה ויש הפרות של ההנחות, נקטו בצעדים המתאימים לטפל בעניין. בנו רווחי סמך בו-זמניים עבור אוסף הקונטרסטים הבא:


$$\psi_1 = \mu_2 - \mu_1, \quad \psi_2 = \mu_3 - \mu_1, \quad \psi_3 = \mu_3 - \mu_2, \quad \psi_4 = \frac{\mu_2 + \mu_3}{2} - \mu_1$$

במודל ניתוח שונות חד-כווני יש לנו שתי הנחות:

1. השגיאה מפולגת נורמלית ( $y_{ij} - \mu_i = \epsilon_{ij} \sim N(0, \sigma_i^2)$ )

2. שוויון שונויות ( $\sigma_1 = \sigma_2 = \dots = \sigma_I$ )

עבור הנתונים בקובץ qn2.txt, נביט ב-QQ-Plot של השאריות וכן נערוך מבחן קולמוגורוב-סמירנוב:



Lilliefors (kolmogorov-smirnov) normality test

data: e  
D = 0.11279, p-value = 0.0001636

כמעט בכל רמת מובהקות, נוכל להכריע כי הנתונים אינם מפולגים נורמלית.

כיוון שגדלי הקבוצות מקיימים  $n_1 = 32, n_2 = 71, n_3 = 37$  נוכל לקרב לפי CLT באופן  $\bar{y}_i \sim N(\mu_i, \frac{\sigma_i^2}{n_i})$  ובשל כך נוכל להשתמש במבחן Levene לשוויון שוניות (למרות שהוא מניח  $(\frac{\epsilon_{ij}}{\sigma_i} \sim N(0,1))$ :

Levene's Test for Homogeneity of Variance (center = "mean")  
Df F value Pr(>F)  
group 2 0.2442 0.7837  
137

מתוצאה זו, לא נדחה את השערת שוויון השוניות ולכן נערוך את מבחן Welch בהתאם:

one-way analysis of means

data: y and G  
F = 7.6979, num df = 2, denom df = 137, p-value = 0.0006788

לפי תוצאות אלו, נדחה את השערת שוויון התוחלות. גם לפי מבחן Kruskal-Wallis נקבל את אותה מסקנה:

kruskal-wallis k-sample test.

Number of samples: 3  
Sample sizes: 32, 71, 37  
Number of ties: 42

Null Hypothesis: All samples come from a common population.

Based on Nsim = 1e+07 simulations

test statistic	asympt. P-value	sim. P-value
11.370000	0.003389	0.002990

כיוון שדחינו את ההנחה על נורמליות השגיאות בנתונים, לא נוכל להשתמש בשיטות שפה וטוקי (טוקי מיועדת להפרשים זוגיים, שפה משתמשת במבחן F); לא מצאנו קשר מהצורה  $\sigma_i \approx c\mu_i^\alpha$  ולכן גם לא מצאנו טרנספורמציה מתאימה לנתונים; כל שנותר לנו הוא רווחי סמך בשיטה המדויקת:

$$\Psi = \begin{cases} \mu_2 - \mu_1 \\ \mu_3 - \mu_1 \\ \mu_3 - \mu_2 \\ \frac{\mu_2 + \mu_3}{2} - \mu_1 \end{cases} \rightarrow C = \begin{pmatrix} -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \\ -1 & 0.5 & 0.5 \end{pmatrix}, \hat{\Psi} = C\hat{\beta} = \begin{cases} \bar{y}_2 - \bar{y}_1 \\ \bar{y}_3 - \bar{y}_1 \\ \bar{y}_3 - \bar{y}_2 \\ \frac{\bar{y}_2 - \bar{y}_3}{2} - \bar{y}_1 \end{cases}$$

$$R = \Omega^{-1}H\Omega^{-1} \rightarrow \hat{\psi}(c^{(k)}) \pm t_{N-I,1-\alpha}^* \cdot s \cdot \sqrt{V(C^{(k)})}$$

$$S(c^{(1)}) = [3.7838, 18.5242]$$

$$S(c^{(2)}) = [6.7803, 23.4929]$$

$$S(c^{(3)}) = [-3.0360, 11.0011]$$

$$S(c^{(4)}) = [6.0913, 20.1993]$$

ובסך הכל נוכל לדחות לחלוטין את ההשערה  $H_0: \mu_1 = \mu_2 = \mu_3$  קוד R:

```
library(car)
library(kSamples)
library(nortest)
library(mvtnorm)
D <- read.table("qn2.txt")
G <- factor(D$V1)
y <- D$V2
N <- length(y)
I <- nlevels(G)
mu.hat <- ave(y, G)
e <- y - mu.hat
# Q-Q plot
qqnorm(e, main = expression("Q-Q Plot for"~e[ij]))
qqline(e, col = 2)
# K-S
lillie.test(e)
#levene
leveneTest(y ~ G, center = "mean")
# Welch
oneway.test(y~G, var.equal = T)
# K-W
y1 <- y[G==1]
y2 <- y[G==2]
y3 <- y[G==3]
qn.test(y1, y2, y3, test = "KW", method = "simulated", Nsim = 1e7)
# CIs
alpha <- 0.1
C <- matrix(c(-1, -1, 0, -1, 1, 0, -1, 0.5, 0, 1, 1, 0.5), ncol = 3)
K <- nrow(C)
mu_i.hat <- tapply(y, G, mean)
n_i <- tapply(y, G, length)
s <- sqrt(sum(e^2)/(N - I))
psi.hat <- C %*% mu_i.hat
V <- diag(s^2 / n_i)
cov.hat <- C %*% V %*% t(C)
H <- cov.hat / s^2
V_i <- sqrt(diag(H))
Omega <- diag(V_i)
R <- solve(Omega) %*% H %*% solve(Omega)
t.crit <- qmvt(p = 1 - alpha, corr = R, tail = "both", df = (N - I))$quantile
w <- t.crit * s * V_i
CI <- cbind(psi.hat - w, psi.hat + w)
```

3. (30 נקודות) בקורס מסוים יש 9 תלמידים. 4 תלמידים למדו ברצינות במהלך הסמסטר והכינו תרגילים באופן שוטף, 5 נוספים לא למדו כלל במהלך הסמסטר ולמדו רק לקראת המבחן. הציונים במבחן הסופי הם:

לומדים באופן שוטף	87	80	77	90	
לומדים רק למבחן	70	75	69	82	85

רוצים לבדוק את ההשערות הבאות:

$H_0$  – לימוד שוטף לא מצביע על ציון סופי גבוה יותר בקורס זה.

$H_1$  – לימוד שוטף מצביע על ציון סופי גבוה יותר בקורס זה.

כיוון שזהו קורס חדש לחלוטין, אין ידע על התפלגות הציונים ונדרש שימוש במבחן לא-פרמטרי.

א. איזה מבחן יתאים לבעיה זו?

ב. מה רמת המובהקות של מבחן הדוחה את  $H_0$  אם סכום הדרגות הרלוונטי גדול או שווה ל-26? יש לחשב את רמת המובהקות במדויק, ללא שימוש בקירוב הנורמלי.

ג. האם, לפי המבחן שבנית סעיף ב', עליך לדחות את  $H_0$ ?

א. כיוון שנדרש מבחן לא-פרמטרי להשוואה בין קבוצות ולא ידועה לנו התפלגות הנתונים, נוכל להשתמש במבחן סכום דרגות של ווילקוקסון.

ב. יש  $\binom{9}{4}$  קומבינציות שונות לסטטיסטי הדרגות, אנחנו מחפשים את אלו בהן סכום הדרגות של קבוצת הלומדים הוא לכל הפחות 26, יש בדיוק 12 כאלו:

$$w = 26: (9,8,7,2), (9,8,6,3), (9,8,5,4), (9,7,6,4), (8,7,6,5)$$

$$w = 27: (9,8,7,3), (9,8,6,4), (9,7,6,5)$$

$$w = 28: (9,8,7,4), (9,8,6,5)$$

$$w = 29: (9,8,7,5)$$

$$w = 30: (9,8,7,6)$$

(את מספר הקומבינציות ניתן היה למצוא באמצעות שאלה 3 בתרגיל 4)

$$P(W_s \geq 26) = \frac{12}{\binom{9}{4}} = \frac{12}{126} = 0.0952 \text{ היא המבחן של } H_0$$

ג. הדרגות של קבוצת הלומדים הן (9,4,5,8), סכומן הוא 26 ולכן לפי המבחן של סעיף ב' עלינו לדחות את  $H_0$  ברמת מובהקות של 0.0952.

4. (20 נקודות) נניח מודל ANOVA דו-כווני עם  $I = J = 2$  וממוצעי קבוצות באופן הבא:

$$\mu_{11} = \theta$$

$$\mu_{12} = \theta + \Delta_B$$

$$\mu_{21} = \theta + \Delta_A$$

$$\mu_{22} = \theta + \Delta_A + \Delta_B + \psi$$

ע"י שימוש בפרמטריזציה  $\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}$  ובמשקלות  $\pi_1 = \pi_2 = \tau_1 = \tau_2 = \frac{1}{2}$ , מצאו ביטויים עבור הרכיבים  $\mu, \alpha_1, \alpha_2, \beta_1, \beta_2, \gamma_{11}, \gamma_{12}, \gamma_{21}, \gamma_{22}$ .

$$\mu_{11} = \mu + \alpha_1 + \beta_1 + \gamma_{11}$$

$$\mu_{12} = \mu + \alpha_1 + \beta_2 + \gamma_{12}$$

$$\mu_{21} = \mu + \alpha_2 + \beta_1 + \gamma_{21}$$

$$\mu_{22} = \mu + \alpha_2 + \beta_2 + \gamma_{22}$$

מאילוצים על הפרמטרים ומהמשקלות השווים נקבל  $\alpha_2 = -\alpha_1$  וכן  $\beta_2 = -\beta_1$ , כמו גם  $\gamma_{22} = -\gamma_{12}$ ,  $\gamma_{21} = -\gamma_{11}$  וכן  $\gamma_{22} = \gamma_{11}$ , כלומר  $\gamma_{12} = -\gamma_{11}$ .

$$\mu = \sum_i \sum_j \pi_i \tau_j \mu_{ij} = \frac{1}{4} (\theta + (\theta + \Delta_B) + (\theta + \Delta_A) + (\theta + \Delta_A + \Delta_B + \psi)) = \theta + \frac{\Delta_A}{2} + \frac{\Delta_B}{2} + \frac{\psi}{4}$$

$$\mu_{12} - \mu_{11} = \beta_2 - \beta_1 + \gamma_{12} - \gamma_{11} = -2\beta_1 - 2\gamma_{11} = \Delta_B \rightarrow -\beta_1 - \gamma_{11} = \frac{\Delta_B}{2}$$

$$\mu_{11} = \mu + \alpha_1 + \beta_1 + \gamma_{11} \rightarrow \alpha_1 = \mu_{11} - \mu - \beta_1 - \gamma_{11} = \theta - \theta - \frac{\Delta_A}{2} - \frac{\Delta_B}{2} - \frac{\psi}{4} + \frac{\Delta_B}{2} = -\frac{\Delta_A}{2} - \frac{\psi}{4}$$

$$\mu_{11} + \mu_{21} = 2\mu + 2\beta_1 = 2\theta + \Delta_A \rightarrow \beta_1 = \theta + \frac{\Delta_A}{2} - \mu = \theta + \frac{\Delta_A}{2} - \theta - \frac{\Delta_A}{2} - \frac{\Delta_B}{2} - \frac{\psi}{4} = -\frac{\Delta_B}{2} - \frac{\psi}{4}$$

$$\begin{aligned}\mu_{11} + \mu_{22} &= 2\mu + 2\gamma_{11} = 2\theta + \Delta_A + \Delta_B + \psi \rightarrow \gamma_{11} = \theta + \frac{\Delta_A}{2} + \frac{\Delta_B}{2} + \frac{\psi}{2} - \mu \\ &= \theta + \frac{\Delta_A}{2} + \frac{\Delta_B}{2} + \frac{\psi}{2} - \theta - \frac{\Delta_A}{2} - \frac{\Delta_B}{2} - \frac{\psi}{4} = \frac{\psi}{4}\end{aligned}$$

ובסך הכל נקבל:

$$\begin{aligned}\mu &= \theta + \frac{\Delta_A}{2} + \frac{\Delta_B}{2} + \frac{\psi}{4} \\ \alpha_1 &= -\frac{\Delta_A}{2} - \frac{\psi}{4} \\ \alpha_2 &= \frac{\Delta_A}{2} + \frac{\psi}{4} \\ \beta_1 &= -\frac{\Delta_B}{2} - \frac{\psi}{4} \\ \beta_2 &= \frac{\Delta_B}{2} + \frac{\psi}{4} \\ \gamma_{11} &= \frac{\psi}{4} \\ \gamma_{12} &= -\frac{\psi}{4} \\ \gamma_{21} &= -\frac{\psi}{4} \\ \gamma_{22} &= \frac{\psi}{4}\end{aligned}$$